

Analiza danych jakościowych

Projekt
Zadowolenie klientów linii lotniczych

Mateusz Pompa

28 styczeń, 2024

1 Informacje o zbiorze danych

1.1 Źródło oraz sposób gromadzenia danych

Dane pobrałem ze strony internetowej [www.kaggle.com](https://www.kaggle.com/datasets/sjleshrac/airlines-customer-satisfaction/data). Zbiór danych został zgromadzony przez anonimową organizację lotniczą, którą na potrzeby projektu nazwiemy Invistico Airlines. Link do danych <https://www.kaggle.com/datasets/sjleshrac/airlines-customer-satisfaction/data>

1.2 Opis danych

Zbiór danych składa się z szczegółowych informacji o klientach, ich lotach oraz ich opiniach związanych z różnymi aspektami podróży. Zmienną objaśnianą jest binarna zmienna 'satisfaction', która oznacza, czy klient był zadowolony, czy niezadowolony z lotu. Zbiór danych zawiera 129 880 obserwacji oraz 22 zmienne objaśniające, których opisy znajdują się poniżej.


Cecha	Opis	Typ zmiennej
Satisfaction	Poziom zadowolenia	factor, 2 levels
Gender	Płeć pasażera	factor, 2 levels
Customer type	Lojalność pasażera	factor, 2 levels
Age	Wiek pasażera	continuous
Type of travel	Cel lotu	factor, 2 levels
Class	Klasa podróży w samolocie	factor, 3 levels
Flight distance	Odległość podróży	continuous
Seat comfort	Ankieta dotycząca komfortu siedzenia	factor, 5 levels
Departure/arrival	Ankieta dot. czasu odlotu/przylotu	factor, 5 levels
Food and drink	Ankieta dot. jedzenia i napojów	factor, 5 levels
Gate location	Ankieta dot. lokalizacji bramki	factor, 5 levels
Inflight WiFi service	Ankieta dot. pokładowej sieci Wi-Fi	factor, 5 levels
Inflight entertainment	Ankieta dot. rozrywki	factor, 5 levels
Online support	Ankieta dot. wsparcia online	factor, 5 levels
Ease of online booking	Ocena dot. rezerwacji online	factor, 5 levels
On-board services	Ankieta dot. wsparcia online	factor, 5 levels
Leg room	Ankieta dot. przestrzeni na nogi	factor, 5 levels
Baggage handling	Ankieta dot. obsługi bagażu	factor, 5 levels
Checkin service	Ocena usługi odprawy	factor, 5 levels
Cleanliness	Ankieta dot. czystości	factor, 5 levels
Online boarding	Ankieta dot. wejścia na pokład "online"	factor, 5 levels
Departure delay	Opóźnienie odlotu	continuous
Arrival delay	Opóźnienie po przylocie	continuous

1.3 Eksploracja i przygotowanie danych

Przed przystąpieniem do analizy danych musimy zapoznać się z naszym zbiorem danych i sprawdzić, czy zmienne są zgodne ze zdrowym rozsądkiem. Zaczynamy od podsumowania ramki danych, aby zobaczyć kilka podstawowych statystyk. Dla każdej zmiennej ilościowej otrzymujemy min., maks., średnią, medianę oraz pierwszy i trzeci kwartył. Z drugiej strony dla każdej zmiennej kategorycznej widzimy liczbę obserwacji w każdej kategorii.

satisfaction		Gender	Customer Type		Age	Type of Travel		Class				
dissatisfied:	58793	Female:	65899	disloyal Customer:	23780	Min.	: 7.00	Business travel:	89693	Business:	62160	
satisfied	: 71087	Male	: 63981	Loyal Customer	: 106100	1st Qu.:	: 27.00	Personal Travel:	40187	Eco	: 58309	
						Median	: 40.00				Eco Plus:	9411
						Mean	: 39.43					
						3rd Qu.:	: 51.00					
						Max.	: 85.00					
Flight Distance		Seat comfort		Departure/Arrival time convenient		Food and drink		Gate location		Inflight wifi service		
Min.	: 50	Min.	: 0.000	Min.	: 0.000	Min.	: 0.000	Min.	: 0.00	Min.	: 0.000	
1st Qu.:	: 1359	1st Qu.:	: 2.000	1st Qu.:	: 2.000	1st Qu.:	: 2.000	1st Qu.:	: 2.00	1st Qu.:	: 2.000	
Median	: 1925	Median	: 3.000	Median	: 3.000	Median	: 3.000	Median	: 3.00	Median	: 3.000	
Mean	: 1981	Mean	: 2.839	Mean	: 2.991	Mean	: 2.852	Mean	: 2.99	Mean	: 3.249	
3rd Qu.:	: 2544	3rd Qu.:	: 4.000	3rd Qu.:	: 4.000	3rd Qu.:	: 4.000	3rd Qu.:	: 4.00	3rd Qu.:	: 4.000	
Max.	: 6951	Max.	: 5.000	Max.	: 5.000	Max.	: 5.000	Max.	: 5.00	Max.	: 5.000	
Inflight entertainment		Online support		Ease of Online booking		On. board service		Leg room service		Baggage handling		
Min.	: 0.000	Min.	: 0.00	Min.	: 0.000	Min.	: 0.000	Min.	: 0.000	Min.	: 1.000	
1st Qu.:	: 2.000	1st Qu.:	: 3.00	1st Qu.:	: 2.000	1st Qu.:	: 3.000	1st Qu.:	: 2.000	1st Qu.:	: 3.000	
Median	: 4.000	Median	: 4.00	Median	: 4.000	Median	: 4.000	Median	: 4.000	Median	: 4.000	
Mean	: 3.383	Mean	: 3.52	Mean	: 3.472	Mean	: 3.465	Mean	: 3.486	Mean	: 3.696	
3rd Qu.:	: 4.000	3rd Qu.:	: 5.00	3rd Qu.:	: 5.000	3rd Qu.:	: 4.000	3rd Qu.:	: 5.000	3rd Qu.:	: 5.000	
Max.	: 5.000	Max.	: 5.00	Max.	: 5.000	Max.	: 5.000	Max.	: 5.000	Max.	: 5.000	
Checkin service		Cleanliness		Online boarding		Departure Delay in Minutes		Arrival Delay in Minutes				
Min.	: 0.000	Min.	: 0.000	Min.	: 0.000	Min.	: 0.00	Min.	: 0.00			
1st Qu.:	: 3.000	1st Qu.:	: 3.000	1st Qu.:	: 2.000	1st Qu.:	: 0.00	1st Qu.:	: 0.00			
Median	: 3.000	Median	: 4.000	Median	: 4.000	Median	: 0.00	Median	: 0.00			
Mean	: 3.341	Mean	: 3.706	Mean	: 3.353	Mean	: 14.71	Mean	: 15.09			
3rd Qu.:	: 4.000	3rd Qu.:	: 5.000	3rd Qu.:	: 4.000	3rd Qu.:	: 12.00	3rd Qu.:	: 13.00			
Max.	: 5.000	Max.	: 5.000	Max.	: 5.000	Max.	: 1592.00	Max.	: 1584.00			
								NA's :393				

Patrząc na podsumowanie danych, nie widzimy żadnych większych problemów i ogólnie statystyki danych wydają się rozsądne. Warto zauważyć, że liczba zadowolonych i niezadowolonych klientów w zbiorze danych jest porównywalna, mamy prawie taką samą liczbę pasażerów płci męskiej i żeńskiej oraz pasażerów podróżujących biznes klasą i klasą eko. Zdecydowanie więcej mamy jednak opinii klientów lojalnych, którzy mogą udzielać więcej przychylnych odpowiedzi w ankiecie niż nielojalni klienci. Warto również zauważyć, że dla odpowiedzi w ankietach opisujących poziom zadowolenia klienta, wartość 0 odzwierciedla sytuację, w której pasażer nie podał odpowiedzi na pytanie. Ponieważ nasz zbiór danych jest bardzo duży usuniemy takie wartości oraz wartości typu Na's, czyli brakujące wartości. Dodatkowo wizualizujemy histogramy cech, aby zobaczyć rozkład zmiennych ciągłych.



Możemy zaobserwować, że:

- opóźnienia odlotów i przylotów są w większości zerowe lub niewielkie,
- najczęstsza odległość lotu wynosi około 2000 kilometrów,
- wiek jest różny, od bardzo małych dzieci do osób starszych po 80. roku życia, ale największa liczba klientów to osoby w wieku od 20 do 60 lat.

Dzielimy zbiór danych na dwie części, jedną do trenowania modelu, a drugą do jego testowania. Ponieważ po usunięciu niepotrzebnych danych mamy do dyspozycji prawie 130 000 obserwacji, 100 000 losowo wybranych trafi do zbioru uczącego, a reszta do zbioru testowego. Teraz, gdy już jesteśmy po wstępnej obróbce i podziale danych, przechodzimy do sformułowania problemu badawczego.

2 Sformułowanie problemu badawczego

Projekt ma na celu analizę danych dotyczących satysfakcji pasażerów Investico Airlines. Mając obserwacje klientów na temat podróży i zgłaszanego poziomu satysfakcji z poszczególnych aspektów lotu, staramy się dopasować model liniowy, które przewiduje, czy są oni zadowoleni z usługi, czy nie.

3 Specyfikacja zastosowanych modeli i ich weryfikacja

Do rozwiązania naszego problemu użyjemy regresji logistycznej. Model regresji logistycznej jest szczególnym przypadkiem uogólnionego modelu liniowego. Cechą objaśnianą jest poziom satysfakcji, który przyjmuje wartości binarne, 1 gdy klient był zadowolony z podróży, 0 w przeciwnym przypadku. W pierwszej kolejności wykonujemy regresję logistyczną dla wszystkich zmiennych na zbiorze uczącym.

```
Call:
glm(formula = IsSatisfied ~ ., family = "binomial", data = airline_train)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-4.3617  -0.3160   0.0276   0.2583   3.5867

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -3.989e+00  1.092e-01 -36.526 < 2e-16 ***
GenderMale    -9.493e-01  2.448e-02 -38.775 < 2e-16 ***
Customer.TypeLoyal Customer  2.840e+00  4.115e-02  69.030 < 2e-16 ***
Age           -3.529e-03  8.405e-04  -4.199 2.68e-05 ***
Type.of.TravelPersonal Travel -1.472e+00  3.604e-02 -40.850 < 2e-16 ***
ClassEco      -4.949e-01  3.189e-02 -15.521 < 2e-16 ***
ClassEco Plus -6.409e-01  4.828e-02 -13.274 < 2e-16 ***
Flight.Distance -9.869e-05  1.236e-05  -7.986 1.40e-15 ***
Seat.comfort2  -3.896e-01  5.576e-02  -6.987 2.80e-12 ***
Seat.comfort3  -4.234e-01  5.559e-02  -7.617 2.60e-14 ***
Seat.comfort4   5.011e-01  5.334e-02   9.394 < 2e-16 ***
Seat.comfort5   5.200e+00  1.164e-01  44.672 < 2e-16 ***
Departure.Arrival.time.convenient -5.299e-01  1.333e-02 -39.762 < 2e-16 ***
Food.and.drink2  3.018e-01  5.928e-02   5.091 3.57e-07 ***
Food.and.drink3  8.832e-01  5.940e-02  14.870 < 2e-16 ***
Food.and.drink4  7.783e-01  5.932e-02  13.120 < 2e-16 ***
Food.and.drink5  9.008e-01  7.047e-02  12.782 < 2e-16 ***
Gate.location2   3.029e-01  4.941e-02   6.131 8.72e-10 ***
Gate.location3   1.135e-01  4.650e-02   2.441 0.014653 *
Gate.location4   2.609e-01  4.772e-02   5.467 4.59e-08 ***
Gate.location5  -1.670e-01  6.486e-02  -2.575 0.010035 *
```

Zauważamy, że zgodnie z tym modelem:

- GenderMale ma ujemny współczynnik -0.9493 . Oznacza to, że mężczyźni (GenderMale = 1) mają niższe prawdopodobieństwo zadowolenia w porównaniu do kobiet (GenderMale = 0).
- Customer.TypeLoyal Customer ma dodatni współczynnik 2.840. Oznacza to, że lojalni klienci mają znacznie wyższe prawdopodobieństwo zadowolenia niż nielojalni klienci.
- Age ma ujemny współczynnik -0.0035 . Oznacza to, że ze wzrostem wieku prawdopodobieństwo zadowolenia maleje, ale ten efekt jest stosunkowo niewielki.

- `Type.of.TravelPersonal Travel` ma ujemny współczynnik -1.472 . Oznacza to, że podróże służbowe (`Personal Travel = 0`) mają wyższe prawdopodobieństwo zadowolenia w porównaniu do prywatnej podróży.
- Zarówno `ClassEco` (-0.495) jak i `ClassEco Plus` (-0.641) mają ujemne współczynniki, co oznacza, że pasażerowie podróżujący klasą ekonomiczną (`Eco`) lub klasą ekonomiczną plus (`Eco Plus`) mają niższe prawdopodobieństwo zadowolenia w porównaniu do pasażerów podróżujących biznes klasą (`Business Class`).
- `Flight.Distance` ma ujemny współczynnik $-9.869 \cdot 10^{-5}$. Oznacza to, że zwiększający się dystans lotu wpływa na zmniejszenie prawdopodobieństwa zadowolenia.
- Wyższe oceny `Online.boarding` (poziomy 3, 4, 5) są związane z większym prawdopodobieństwem zadowolenia pasażerów, podczas gdy dla poziomu 2 nie ma statystycznych dowodów na różnice w zadowoleniu.

To, co wydaje się nieintuicyjne, to fakt, że biorąc pod uwagę `Inflight.wifi.service` i `Gate.location`, poziom zadowolenia jest wyższy w przypadku ocen średnich niż wysokich. Wszystkie zmienne istotne. Próbuje sprawdzić inne modele, usuwając kolumny dla których p wartości są największe. Przykładowy model bez kolumny `dot. opinii` na temat sieci Wi-Fi na pokładzie:

```
Call:
glm(formula = IsSatisfied ~ . - Inflight.wifi.service, family = "binomial",
    data = airline_train)
```

Spróbujemy skorzystać z regresji krokowej (wstecznej), która powinna usunąć ze zbioru zmiennych, te które mają najmniej wpływ na zmienną zależną. Niestety dla naszego przykładu funkcja nie usunęła żadnej kolumny.

Po estymacji kilku modeli, chcielibyśmy wybrać najlepszy. Skorzystamy z kryterium informacyjnego Akaike (AIC). Kryterium sugeruje żebyśmy wybrali model pierwszy z wszystkimi zmiennymi, ponieważ charakteryzuje się najmniejszą wartością AIC.

- 48652.7 - dla wszystkich zmiennych,
- 48704.62 - po usunięciu kolumny `Inflight.wifi.service`
- 48652.7 - regresja krokowa, która zwróciła nam pełny model (tzn. pierwszy model dla wszystkich zmiennych),
- 51420 - dla modelu z interakcjami pomiędzy pewnymi zmiennymi

4 Interpretacja wyników analizy statystycznej

```
Call:
glm(formula = IsSatisfied ~ ., family = "binomial", data = airline_train)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-4.3617  -0.3160   0.0276   0.2583   3.5867

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -3.989e+00  1.092e-01 -36.526 < 2e-16 ***
GenderMale    -9.493e-01  2.448e-02 -38.775 < 2e-16 ***
Customer.TypeLoyal Customer  2.840e+00  4.115e-02  69.030 < 2e-16 ***
Age          -3.529e-03  8.405e-04  -4.199 2.68e-05 ***
Type.of.TravelPersonal Travel -1.472e+00  3.604e-02 -40.850 < 2e-16 ***
ClassEco      -4.949e-01  3.189e-02 -15.521 < 2e-16 ***
ClassEco Plus -6.409e-01  4.828e-02 -13.274 < 2e-16 ***
Flight.Distance -9.869e-05  1.236e-05  -7.986 1.40e-15 ***

...                ...                ...                ...                ...

Online.boarding2  -7.203e-02  6.139e-02  -1.173 0.240630
Online.boarding3   4.448e-01  5.581e-02   7.969 1.59e-15 ***
Online.boarding4   2.279e-01  5.567e-02   4.095 4.22e-05 ***
Online.boarding5   6.156e-01  6.313e-02   9.751 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 137924  on 99999  degrees of freedom
Residual deviance:  48531  on 99939  degrees of freedom
AIC: 48653

Number of Fisher Scoring iterations: 7
```

Model regresji liniowej możemy zatem zapisać jako:

$$\log\left(\frac{p(x)}{1-p(x)}\right) = -3,989 - 0.09493x_{\text{GenderMale}} + 2,84x_{\text{Customer.TypeLoyalCustomer}} - 0.003529x_{\text{Age}} - \dots$$

Kolejna kolumna zawiera błędy standardowe współczynników. Jeśli podzielimy przez nie wartości odpowiadających im współczynników, to otrzymamy wartości tzw. statystyki Walda. Znajdziemy je w następnej kolumnie. Przy założeniu, że współczynnik jest równy 0, czyli odpowiadająca mu zmienna nie ma wpływu na wynik, statystyka ta ma w przybliżeniu standardowy

rozkład normalny. Możliwe jest więc wskazanie p-wartości (mamy je w kolejnej kolumnie) i ewentualne odrzucenie hipotezy o nieistotności czynnika. W naszym przykładzie wszystkie p-wartości są małe ($< 5\%$), zatem na wynik wpływa każda ze zmiennych.

Estymacja współczynników polega na maksymalizowaniu funkcji wiarygodności, czyli na takim ich dobraniu, by uzyskać największą wartość wyrażenia

$$\prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}$$

gdzie x_i jest wektorem wartości zmiennych objaśniających dla i -tej obserwacji, a y_i jest równe 1, jeśli i -ta obserwacja jest sukcesem. Dla porażki y_i przyjmuje wartość 0. W praktyce rozwiązuje się równoważny problem polegający na maksymalizacji logarytmu funkcji wiarygodności. W naszym przykładzie program wykorzystał do tego algorytm Fishera. Możemy łatwo odczytać zmaksymalizowaną wartość.

$$'logLik.' - 24265.35(df = 61)$$

Mnożąc ją razy -2 , otrzymamy dewiancję, która także pozwala ocenić istotność zmiennych uwzględnionych w modelu.

$$'logLik.' 48530.7(df = 61)$$


Mogliśmy ją odczytać już wcześniej (Residual deviance). Była ona zestawiona z dewiancją modelu pozbawionego wszelkich predyktorów (Null deviance). Przy założeniu braku istotności zmiennych dla dużej liczby obserwacji różnica tych dwóch dewiancji ma rozkład χ^2 o liczbie stopni swobody równej liczbie zmiennych niezależnych w modelu, czyli w naszym przypadku 60. Policzona p -wartość wynosi 0. Z dwóch różnych modeli lepiej dopasowany jest ten, który ma mniejszą dewiancję.

5 Podsumowanie

Teraz przeanalizujemy działanie modelu. Korzystając z kryterium AIC wybraliśmy model ze wszystkimi zmiennymi.

```
call:  
glm(formula = Issatisfied ~ ., family = "binomial", data = airline_train)
```

Dokładność naszego modelu wynosi 0.897896650220722, a precyzja wynosi 0.909329957148422. Krzywa ROC (z ang. Receiver Operating Characteristic) to wykres zależności pomiędzy skutecznością klasyfikacji pozytywnych (Czułość) a nieskutecznością klasyfikacji przypadków negatywnych (1-Swoistość) na każdym poziomie prawdopodobieństwa. Krzywa ROC obrazuje więc, jak duży będzie odsetek błędnych klasyfikacji (pozytywnych i negatywnych) dla danego punktu odcięcia. W jaki sposób założone graniczne prawdopodobieństwo przypisania do kategorii pozytywnej (wystąpienie zjawiska) równocześnie na poprawną i błędną klasyfikację tychże przypadków. Całe pole pod krzywą (AUC-area under curve) danej krzywej ROC jest ważną statystyką odzwierciedlającą prawdopodobieństwo, że kolejność predykcji na podstawie obserwacji zmiennej testowanej będzie prawidłowa.



Ten model regresji logistycznej ma AUC wynoszące 0.9636 w przypadku danych treningowych i 0.9619 w przypadku danych testowych. Różnica jest marginalna.. Co więcej, widzimy (na wykresie krzywej ROC), że nasz klasyfikator jest bliski doskonałości.